

Avaliação Semântica de Super-Resolução Temporal em Imagens Sentinel-2 por Métricas de PLN

Marcel Fernandes Gomes

PPGC – UFRGS

CMP617 – Processamento de Linguagem Natural e Recuperação de Informações

10 de junho de 2026


Motivação: o que muda quando aumentamos a resolução?

- Sentinel-2: cobertura global, mas ≈ 10 m/px
⇒ limita feições finas (bordas de campo, corpos d'água pequenos, estradas vicinais.)
- Super-resolução (SR) temporal: fusão de múltiplas observações
⇒ $\approx 2,5$ m/px
- PSNR/SSIM são métricas clássicas que avaliam apenas valores numéricos de *pixels*, e não significado.

Problema central

Como saber se o conteúdo recuperado é *semanticamente correto*?

Tiles representativos das duas regiões — LR / SR / GT



LR

SR

GT

Proposta: pipeline de avaliação semântica

Ideia central

Usar modelos visão-linguagem para *descrever* as imagens LR e SR e comparar as descrições com referências conhecidas — sem par HR alinhado.

Três eixos de avaliação:

- 1 **NLP (texto $\leftrightarrow$ texto)**: BLIP/GeoChat geram legendas $\rightarrow$ BLEU-1, ROUGE-1, TF-IDF
- 2 **CLIPScore (imagem $\leftrightarrow$ imagem)**: embeddings CLIP e RemoteCLIP comparam SR e GT
- 3 **VQA estratificada**: GeoChat responde 7 perguntas objetivas em 3 níveis

Contribuição central: avaliação cruzada VQA $\times$ GeoPackage

$\rightarrow$ estima cobertura do solo, compara com GT vetorial em pontos percentuais (pp)

Validação: pipeline replicado em duas regiões geográficas distintas ($n = 953$ tiles).

Dados e configuração experimental

Imagens — Sul do Brasil

- **LR:** Sentinel-2 nativo, $\approx 11,5$ m/px (distorção ao afastar da Linha do Equador)
- **SR:** fusão temporal de 8 obs., $\approx 2,5$ m/px
- **GT raster:** ortofoto aérea, ≈ 1 m/px
- **GT vetorial:** GeoPackage com 7 classes de cobertura do solo

Tiling: grade 64×64 px no espaço LR ($\approx 0,73$ km²/tile)

Duas regiões (≈ 110 km entre si):

	R1	R2
Tiles válidos	575	378
Paisagem	mista	agrícola
Água	frequente	rara
Total	953 tiles	

Cenários de referência:

- **A:** nome da classe vetorial
- **B:** legenda/embedding da ortofoto
- **C:** igual a B, GT reamostrado para SR

Eixo 1 — NLP com BLIP: alucinações e limitação léxica

Cenário A (GT = nome da classe): scores próximos de zero em ambas resoluções

- BLIP raramente reproduz literalmente "forest", "bare ground", etc.
- **Mas revela algo importante sobre a LR:**

20% dos tiles LR geram alucinações

"a blue sky with clouds", "a couple is kissing in the water"

⇒ baixa resolução leva o BLIP a evocar cenas do pré-treinamento

SR reduz esse colapso de **20%** para **11%** dos tiles

Cenário B (GT = legenda da ortofoto): resultado mais limpo

- TF-IDF (pooled): LR = 0,079 SR = 0,279 $\Delta = +0,201$
- Favorável à SR em 685/953 tiles (pooled)

Limitação: BLIP infla o gap porque colapsa na LR. Motiva o uso do GeoChat.

Eixo 2 — CLIPScore imagem-imagem

RemoteCLIP mede diretamente: a SR é mais parecida com a ortofoto?

Modelo	Região	Δ	SR > LR
CLIP gen.	R1	+0,356	562/575
	R2	+0,345	368/378
	pooled	+0,352	930/953
RemoteCLIP	R1	+0,505	574/575
	R2	+0,512	378/378
	pooled	+0,508	952/953

- RemoteCLIP (fine-tuned em SR) é mais sensível que CLIP genérico
- Resultado mais estável entre regiões de todos os eixos
- Diferença SR > LR significativa (teste de sinais, $p < 0,001$)
- Cenário C (GT reamostrado): gap cai de +0,508 para +0,421
⇒ parte da vantagem é resolução diferencial, mas hierarquia LR < SR persiste

Eixo 3 — VQA estratificada com GeoChat

GeoChat-7B: modelo visão-linguagem ajustado em 318 mil pares geoespaciais

⇒ descreve bem baixa e super-resolução — gap menor que BLIP confirma que o ganho é real

Nível	Pergunta
L1 Semântico	<i>"Estimate the percentage of each land cover type"</i>
	<i>"Is there a water body visible in the image?"</i>
L2 Estrutural	<i>"How many distinct agricultural fields can you count?"</i>
	<i>"Are crop rows or cultivation patterns visible?"</i>
L3 Detalhe fino	<i>"How many individual buildings are visible?"</i>
	<i>"Describe the road network visible in the image"</i>
	<i>"Describe the buildings visible in the image"</i>

Nível	TF-IDF Δ	Sem. Δ
L1 Semântico	+0,228	+0,054
L2 Estrutural	+0,131	+0,044
L3 Detalhe fino	+0,122	+0,056

- SR favorável em todos os níveis e regiões
- L2 mais fraco: contagem de campos satura em zero para ambas as resoluções
- L3 maior na Região 2: paisagem agrícola se beneficia mais dos detalhes finos

Contribuição central: VQA × GeoPackage

Problema com Cenários A–C

Comparação textual depende de sobreposição léxica ou alinhamento de resolução. O que queremos: **a SR estima melhor a cobertura real do solo?**

Método:


- 1 GeoChat responde Q1: *“Estimate the percentage of each land cover type”*
- 2 Extraímos as porcentagens estimadas para baixa resolução, super-resolução e GT raster
- 3 Calculamos o erro absoluto médio contra as porcentagens reais do GeoPackage (ground truth vetorial)

⇒ métrica em **pontos percentuais (pp)**, diretamente interpretável, sem depender de léxico ou par HR alinhado

Resultado principal: MAE de cobertura LR vs. SR vs. GT

Classe	R1		R2		Pooled	
	LR	SR	LR	SR	LR	SR
forest	37,1	36,6	28,8	23,9	33,8	31,6
agriculture	30,4	26,1	50,1	41,0	38,3	31,9
urban	5,1	3,7	5,0	5,8	5,1	4,5
water	11,5	9,6	4,7	13,4	8,8	11,1
bare soil	29,4	20,2	24,4	10,3	27,4	16,4
Global	22,7	19,2	22,6	18,9	22,7	19,1
GT raster	17,7		16,9		17,4	

Menor MAE = melhor. $\Delta_{\text{pooled}} = +3,6 \text{ pp (LR-SR)}$.



Ganho da SR por classe e região

Hierarquia e maiores ganhos

$$\underbrace{\text{GT raster}}_{17,4 \text{ pp}} < \underbrace{\text{SR}}_{19,1 \text{ pp}} < \underbrace{\text{LR}}_{22,7 \text{ pp}} \quad (\text{MAE global pooled})$$

Maiores ganhos (pooled):

- **bare soil: +11,1 pp**
robustos nas duas regiões (+9,2 / +14,0)
 - **agriculture: +6,3 pp**
especialmente R2 (+9,2 pp)
- ⇒ fusão temporal recupera informação semântica real sobre cobertura relevante para monitoramento agrícola/ambiental

Nuance: classe water

- R1 (água frequente): SR melhora (+1,9 pp)
- R2 (água rara): SR superestima (−8,7 pp)
- pooled: −2,3 pp

Onde a água é rara, a SR tende a superestimá-la — lembrete de calibrar expectativas por tipo de paisagem.

O que a multi-região confirmou:

- Ganhos globais são consistentes ($R1 \approx R2$ na maioria das métricas)
- RemoteCLIP: +0,505 / +0,512 praticamente idênticos
- Ganhos em bare soil e agriculture reproduzíveis

O que a multi-região revelou:

- Ganhos se mantêm em paisagem mais agrícola ($R2$)
- Ganho global pode coexistir com nuance por classe (ex.: *water* em $R2$)
- Robustez não atestável por estudo de área única

Resumo: o que cada eixo mede

Eixo	O que mede	Principal achado
BLIP NLP	Qualidade léxica das legendas	SR reduz alucinações de 20% → 11%
CLIPScore RemoteCLIP	Similaridade semântica imagem-imagem	SR > LR em 952/953 tiles
GeoChat NLP	Qualidade com modelo robusto	Gap menor confirma que BLIP infla o resultado
VQA estratificada	Informação discriminada por nível	Todos os níveis favorecem SR
VQA × GeoPackage	Erro de cobertura em pp	−3,6 pp global; maior em bare soil e agriculture

Conclusão e trabalhos futuros

Resposta à pergunta central

Sim: a SR por fusão temporal recupera conteúdo semântico mensurável — e o pipeline proposto quantifica esse ganho sem métricas de pixel.

Contribuições:

- 1 Pipeline semântico (NLP + CLIPScore + VQA) para avaliação de SR de satélite
- 2 **Avaliação cruzada VQA × GeoPackage:** métrica quantitativa em pp, sem dependência léxica
- 3 Validação multi-região que confirma robustez e expõe modo de falha (water em R2)

Trabalhos futuros:

- Reformular perguntas VQA de nível estrutural (q03 saturou)
- Ampliar para mais regiões, datas e condições de nuvem

PLN como métrica

O pipeline proposto demonstra que métricas de PLN — do modelo vetorial TF-IDF ao CLIPScore com RemoteCLIP, passando pela VQA com GeoChat — discriminam com consistência a qualidade semântica de imagens SR. Esse resultado sugere que é possível empregar essas métricas como proxy complementar de função de perda no treinamento de redes de SR, enriquecendo a compreensibilidade semântica da imagem reconstruída.

Obrigado!