

Avaliação Semântica de Super-Resolução Temporal em Imagens Sentinel-2 por Métricas de Processamento de Linguagem Natural

Marcel Fernandes Gomes¹

¹Instituto de Informatica – Universidade Federal do Rio Grande do Sul (UFRGS)
Porto Alegre – RS – Brasil

marcelgfernandes@gmail.com

Abstract. *Super-resolution (SR) recovers high-frequency detail from low-resolution satellite imagery, but assessing whether the recovered content is semantically meaningful remains open. This work proposes a pipeline that uses Natural Language Processing (NLP) metrics and vision-language models to evaluate the semantic quality of super-resolved Sentinel-2 images, without pixel-wise metrics. Low-resolution (LR, ≈ 11.5 m/px) and super-resolved (SR, ≈ 2.4 m/px) patches are captioned with BLIP and GeoChat and scored with BLEU-1, ROUGE-1, TF-IDF cosine similarity, CLIPScore (generic CLIP and RemoteCLIP) and a stratified Visual Question Answering (VQA) protocol. The central contribution maps VQA land-cover estimates onto a vector ground truth, eliminating lexical dependence and yielding an interpretable error in percentage points: SR cuts the global estimation error from 22.7 to 19.1 pp, with the largest gains in bare soil (+11.1 pp) and agriculture (+6.3 pp). Validated on **two geographically distinct regions** (953 pooled tiles), RemoteCLIP image-image gains reach +0.51 (952/953 tiles), confirming a robust and consistent semantic improvement.*

Resumo. *Técnicas de super-resolução (SR) recuperam detalhes de alta frequência em imagens de satélite de baixa resolução, mas avaliar se o conteúdo recuperado é semanticamente relevante permanece um problema em aberto. Este trabalho propõe um pipeline que usa métricas de Processamento de Linguagem Natural (PLN) e modelos visão-linguagem para mensurar a qualidade semântica de imagens Sentinel-2 super-resolvidas, sem métricas por pixel. Recortes de baixa resolução (LR, $\approx 11,5$ m/px) e super-resolvidos (SR, $\approx 2,4$ m/px) são legendados por BLIP e GeoChat e pontuados por BLEU-1, ROUGE-1, cosseno TF-IDF, CLIPScore (CLIP genérico e RemoteCLIP) e um protocolo de Visual Question Answering (VQA) estratificado. A contribuição central mapeia as estimativas de cobertura do solo do VQA contra um ground truth vetorial, eliminando a dependência léxica e gerando um erro interpretável em pontos percentuais: a SR reduz o erro global de 22,7 para 19,1 pp, com maiores ganhos em solo exposto (+11,1 pp) e agricultura (+6,3 pp). Validado em **duas regiões geograficamente distintas** (953 tiles combinados), os ganhos RemoteCLIP imagem-imagem chegam a +0,51 (952/953 tiles), confirmando uma melhora semântica robusta e consistente.*

1. Introdução

O monitoramento terrestre por satélite depende fortemente da resolução espacial dos sensores. O Sentinel-2 (Agência Espacial Europeia) oferece cobertura global multitemporal com resolução nativa de 10 m/px nas bandas de cor natural, o que limita a identificação de feições finas como bordas de campos, pequenos corpos d'água e estruturas urbanas de menor porte. Técnicas de super-resolução (SR) por aprendizado profundo reconstroem imagens de resolução mais alta a partir de múltiplas observações temporais de baixa resolução [Dong et al. 2016, Nguyen et al. 2021].

Um desafio central é a *avaliação* das imagens super-resolvidas. Métricas tradicionais como PSNR e SSIM operam em nível de pixel e medem fidelidade fotométrica, mas não capturam se o conteúdo semântico recuperado é coerente com a realidade do terreno: uma imagem SR pode ter PSNR alto e ainda introduzir texturas incorretas que confundem sistemas de classificação. Modelos de visão-linguagem como CLIP [Radford et al. 2021] e BLIP [Li et al. 2022] abrem uma alternativa — avaliar imagens por meio de linguagem natural — e o CLIPScore [Hessel et al. 2021] formaliza essa ideia como similaridade entre embeddings de imagem e texto.

Este trabalho investiga a questão: **as imagens Sentinel-2 super-resolvidas por fusão temporal recuperam conteúdo semântico mensurável frente às versões de baixa resolução, quando avaliadas por métricas de PLN e modelos visão-linguagem?** As contribuições são: (i) o uso de CLIPScore como métrica *comparativa* entre resoluções, sem exigir par de alta resolução perfeitamente alinhado; (ii) a substituição do BLIP genérico pelo GeoChat [Kuckreja et al. 2024], especializado em sensoriamento remoto, sob uma avaliação VQA estratificada em três níveis de sensibilidade à resolução; (iii) a contribuição central: uma avaliação cruzada entre as estimativas de cobertura do solo do VQA e um ground truth vetorial (GeoPackage), que elimina a dependência léxica e produz uma métrica quantitativa interpretável em pontos percentuais; e (iv) a validação do pipeline em **duas regiões geograficamente distintas** do Sul do Brasil, confirmando que os ganhos semânticos são consistentes entre paisagens distintas e revelando modos de falha específicos à composição da paisagem.

2. Referencial Teórico

Super-resolução de satélite. SR é o problema inverso de estimar uma imagem de alta resolução a partir de uma ou mais de baixa resolução [Dong et al. 2016]. A abordagem multitemporal explora o fato de que o satélite revisita a mesma área periodicamente: variações sub-pixel entre observações carregam informação complementar que, combinada, reconstrói detalhes abaixo da resolução nativa [Nguyen et al. 2021].

Legendagem de imagens. BLIP (*Bootstrapping Language-Image Pre-training*) [Li et al. 2022] gera descrições textuais a partir de imagens. Pré-treinado em pares imagem-texto da Web, produz legendas de vocabulário diversificado, mas genérico. GeoChat [Kuckreja et al. 2024], ao contrário, é um modelo visão-linguagem (arquitetura LLaVA, encoder CLIP, decodificador LLaMA-7B) *fine-tuned* em 318 mil pares de instrução geoespaciais, cobrindo legendagem, localização e VQA sobre imagens de satélite — o que o torna mais discriminativo no domínio.

Embeddings visão-linguagem. CLIP [Radford et al. 2021] aprende um espaço latente compartilhado entre imagem e texto por *contrastive learning*; a similaridade cos-

seno nesse espaço mede alinhamento semântico. RemoteCLIP [Liu et al. 2024] especializa o CLIP para sensoriamento remoto (datasets RSICD, RSITMD, UCM), desenvolvendo representações mais discriminativas para classes de cobertura do solo.

Métricas de PLN. *BLEU-1* [Papineni et al. 2002] mede precisão de unigramas (correspondência léxica). *ROUGE-1* [Lin 2004] combina revocação e precisão de unigramas via F1. A *similaridade cosseno TF-IDF* representa cada texto como vetor TF-IDF e, pelo IDF, atenua o peso de termos muito frequentes, focando nos discriminativos; como toda representação léxica, porém, não captura sinonímia. Para superar essa dependência léxica, a *similaridade semântica* emprega um modelo Sentence-BERT (SBERT) [Reimers and Gurevych 2019], que projeta sentenças em um espaço vetorial onde o cosseno reflete proximidade de significado. O **CLIPScore** [Hessel et al. 2021] é definido como

$$\text{CLIP-S}(c, v) = w \cdot \max(\cos(\mathbf{e}_c, \mathbf{e}_v), 0), \quad (1)$$

onde $\mathbf{e}_c$ e $\mathbf{e}_v$ são os embeddings de texto e imagem e $w = 2,5$ é um fator de escala. Pode operar no modo imagem-texto ou imagem-imagem (comparando duas imagens no espaço semântico).

3. Trabalhos Relacionados

A avaliação de qualidade de SR é historicamente dominada por métricas de distorção como PSNR e SSIM [Wang et al. 2004], hoje reconhecidas como fracamente correlacionadas com a percepção humana e com o desempenho em tarefas *downstream* [Blau and Michaeli 2018]. Blau e Michaeli (2018) formalizaram o *perception-distortion tradeoff*, mostrando que melhorar a qualidade perceptual frequentemente piora a fidelidade de pixel — o que motiva métricas alternativas. No domínio de sensoriamento remoto, Nguyen et al. [Nguyen et al. 2021] propõem um benchmark de SR multitemporal para Sentinel-2 avaliado por PSNR/SSIM contra imagens de alta resolução; o presente trabalho difere por usar linguagem natural como referência semântica, dispensando um par HR perfeitamente alinhado.

A legendagem de imagens de sensoriamento remoto foi explorada em datasets como RSICD [Lu et al. 2018], com modelos do tipo BLIP. Hessel et al. [Hessel et al. 2021] introduziram o CLIPScore como avaliação referência-livre com alta correlação humana, e Liu et al. [Liu et al. 2024] o estenderam ao domínio aéreo com o RemoteCLIP. Diferentemente desses trabalhos, aqui o CLIPScore é usado como métrica *comparativa entre resoluções* (LR vs. SR), e a etapa de avaliação cruzada VQA $\times$ GeoPackage elimina a dependência léxica ao substituir a comparação textual por uma métrica quantitativa de estimativa de cobertura do solo. A validade dos ganhos é confirmada em *múltiplas regiões*, e não em uma única cena.

4. Metodologia

A Tabela 1 resume os modelos, métricas e cenários combinados ao longo do trabalho. O mesmo pipeline é executado independentemente em duas regiões.

4.1. Dados e Regiões

As entradas são cenas Sentinel-2 (canal TCI, composição RGB das bandas 4-3-2), no Sul do Brasil. A imagem de baixa resolução (**LR**) tem $\approx 11,5$ m/px; a super-resolvida (**SR**)

Tabela 1. Visão geral do pipeline: modelos, métricas e cenários. ✓ = aplicado; — = não aplicado.

Modelo	Métrica / Modo	Cen. A	Cen. B	Cen. C
BLIP	NLP (BLEU, ROUGE, TF-IDF)	✓	✓	✓
	CLIPScore img↔texto	✓	—	—
(sem modelo)	CLIPScore img↔img [†]	—	✓	✓
GeoChat	NLP (BLEU, ROUGE, TF-IDF)	—	✓	—
	VQA estratificada (7 perguntas)	✓	—	—
	VQA × GeoPackage (MAE q01)	✓	—	—

[†]O modo img↔img extrai embeddings visuais de LR, SR e GT diretamente pelo encoder CLIP, sem modelo de legendagem.

é o produto *blended* por fusão temporal de 8 observações, a $\approx 2,4$ m/px. O ground truth raster (**GT**) é uma ortofoto aérea de ≈ 1 m/px; o ground truth vetorial é um GeoPackage com 7 camadas de cobertura do solo (floresta, campo, massa d’água, terreno exposto, brejo/pântano, vegetação cultivada, área edificada), de anotação manual.

Para validar a robustez do pipeline, o experimento é replicado em **duas regiões geograficamente distintas** (≈ 110 km de distância em EPSG:3857): **Região 1** ($n = 575$ tiles válidos) e **Região 2** ($n = 378$ tiles), totalizando **953 tiles** combinados. As regiões diferem em composição de paisagem — a Região 2 é mais agrícola e tem corpos d’água raros e pequenos —, o que permite identificar tanto a consistência dos ganhos entre paisagens como modos de falha específicos à composição local.

4.2. Reprojecção, Tiling e Atribuição de Classe

Todas as imagens são reprojctadas para EPSG:3857 (Rasterio). O GT é carregado em duas versões: original (≈ 1 m/px) e reamostrado bilinearmente para $\approx 2,4$ m/px (resolução da SR). As imagens são particionadas em um grid de tiles de 64×64 px no espaço LR ($\approx 0,73$ km²/tile); tiles com $> 50\%$ de NoData são descartados. Para cada tile, os polígonos vetoriais são intersectados com sua *bounding box*; a classe dominante é atribuída quando a interseção supera 5% da área. Na Região 1, 437/575 tiles têm classe dominante (Cenário A); na Região 2, todos os 378.

4.3. Cenários e Métricas

Definem-se três cenários de referência: **(A) GT Vetorial** — referência = nome da classe em inglês; **(B) GT Raster 1m** — referência = legenda BLIP da ortofoto (NLP) ou embedding da ortofoto (CLIPScore imagem-imagem); **(C) GT Raster Reamostrado** — idêntico a B, com GT degradado para $\approx 2,4$ m/px, isolando a penalidade de resolução diferencial.

As métricas NLP são BLEU-1 (suavização *method1*, NLTK), ROUGE-1 F1 e cosseno TF-IDF. O CLIPScore usa clip-vit-base-patch32 (genérico) e RemoteCLIP-ViT-B-32, com $w = 2,5$ sobre embeddings normalizados. As legendas livres são geradas por blip-image-captioning-base e, no Cenário B, também pelo GeoChat-7B (FP16 em V100, ou NF4 de 4 bits em GPUs menores), permitindo comparação direta entre os dois modelos.

4.4. VQA Estratificada

Legendas livres saturam quando o modelo descreve bem ambas as resoluções. Para isolar o que a resolução muda, o GeoChat é consultado com 7 perguntas objetivas em 3 níveis: **L1 – Semântico** (q01 estimativa percentual de classes; q02 presença de água); **L2 – Estrutural** (q03 contagem de campos; q04 fileiras de cultivo); **L3 – Detalhe fino** (q05–q07 contagem/descrição de edifícios e vias). A hipótese é que L3 favoreça mais a SR. As respostas LR, SR e GT são comparadas par a par por cosseno TF-IDF, similaridade semântica (SBERT, `all-MiniLM-L6-v2`) e, para q01, MAE em pontos percentuais (pp).

4.5. Avaliação Cruzada VQA × GeoPackage

Para contornar a incompatibilidade léxica do Cenário A, as respostas de q01 são usadas como previsões e o GeoPackage como ground truth quantitativo. Para cada tile: (i) as camadas vetoriais são intersectadas com sua *bbox* e agregadas em 5 classes VQA — *forest*, *agriculture* (campo + vegetação cultivada), *urban*, *water*, *bare soil* (terreno exposto + brejo); (ii) as estimativas percentuais de q01 (LR, SR, GT) são parseadas; (iii) calcula-se o MAE por classe e global. Isso substitui a comparação textual por uma quantitativa, interpretável em pp e comparável entre resoluções.

5. Experimentos e Resultados

Os experimentos usam Python 3.13, PyTorch 2.x, Transformers 5.x, `open_clip_torch` 2.x e Rasterio 1.3. As etapas BLIP rodam em CPU; as etapas GeoChat em GPU Tesla V100-32GB (FP16) e, localmente, em Quadro RTX 4000 (NF4). Os resultados são reportados por região (R1, R2) e combinados (pooled, $n = 953$), de modo que a coluna pooled mede o comportamento agregado e a comparação R1 vs. R2 mede a robustez. A direção das diferenças LR vs. SR é resumida pela fração de tiles em que $SR > LR$ (coluna $SR > LR$ das tabelas): nas métricas principais essa fração é largamente majoritária (p. ex. 952/953 no RemoteCLIP imagem-imagem), indicando que os ganhos são consistentes entre tiles e não atribuíveis a poucos casos extremos.

5.1. Cenário A: limitação léxica

No Cenário A, os scores NLP ficam próximos de zero em ambas as resoluções e regiões (TF-IDF $SR \approx 0,02$ – $0,03$; $SR > LR$ em apenas 71/815 tiles combinados), pois o BLIP raramente reproduz literalmente o nome da classe. A análise qualitativa explica o piso da LR: 20% dos tiles LR da Região 1 geram descrições alucinadas — medido no Cenário B, como legendas com BLEU-1 ≈ 0 frente à ortofoto (p. ex. “*a blue sky with clouds*”, “*a couple is kissing in the water*”) —, pois a resolução insuficiente leva o BLIP a evocar cenas do seu pré-treinamento; a SR reduz esse colapso para 11%. Esse cenário motiva a avaliação cruzada quantitativa da Seção 5.4.

5.2. Cenários B e C: CLIPScore e NLP imagem-imagem

O CLIPScore imagem-imagem (Cenário B) é o resultado mais expressivo e o mais *estável* entre regiões (Tabela 2). O RemoteCLIP classifica a SR como mais próxima da ortofoto em **952/953** tiles ($\Delta = +0,508$ pooled), com ganho praticamente idêntico em R1 (+0,505) e R2 (+0,512). O CLIP genérico confirma a direção com magnitude menor,

indicando que o modelo especializado captura melhor as diferenças de qualidade relevantes ao domínio. As métricas NLP do BLIP (Cenário B) também favorecem a SR de forma consistente nas duas regiões: BLEU-1 $\Delta = +0,157$, ROUGE-1 $+0,189$ e TF-IDF $+0,201$ (pooled), com 657–700/953 tiles favoráveis. No Cenário C (GT reamostrado), os ganhos NLP se mantêm ($\Delta_{\text{TF-IDF}} = +0,227$), enquanto o gap RemoteCLIP comprime de $+0,508$ para $+0,421$: parte da vantagem medida pelo CLIP é penalidade de resolução, mas a hierarquia $\text{LR} < \text{SR}$ persiste mesmo após equalizar as resoluções.

Tabela 2. CLIPScore imagem-imagem (Cenário B) e NLP-BLIP (Cenário B) por região e combinado. $\Delta = \text{SR} - \text{LR}$.

Métrica	Região	LR	SR	Δ	SR>LR
CLIP genérico	R1	1,846	2,203	+0,356	562/575
	R2	1,880	2,225	+0,345	368/378
	pooled	1,860	2,211	+0,352	930/953
RemoteCLIP	R1	1,543	2,048	+0,505	574/575
	R2	1,515	2,027	+0,512	378/378
	pooled	1,532	2,040	+0,508	952/953
BLIP TF-IDF	R1	0,077	0,286	+0,209	403/575
	R2	0,081	0,269	+0,188	282/378
	pooled	0,079	0,279	+0,201	685/953

5.3. GeoChat: legendas livres e VQA estratificada

Substituir o BLIP pelo GeoChat eleva os scores absolutos (TF-IDF SR de 0,279 para 0,769 pooled) e *reduz* o gap relativo ($\Delta_{\text{TF-IDF}} = +0,099$): o GeoChat descreve bem também a LR e não alucina, confirmando que o ganho da SR é real e que o BLIP inflava o gap ao colapsar na LR. Notavelmente, os ganhos GeoChat são *maiores* na Região 2 (BLEU-1 $+0,120$ vs. $+0,086$ em R1), indicando que a paisagem mais agrícola da R2 se beneficia mais da SR na legendagem.

A VQA estratificada (Tabela 3) favorece a SR em todos os níveis e nas duas regiões. O nível semântico (L1) tem o maior ganho TF-IDF ($+0,228$ pooled), puxado por q02 (presença de água, $\Delta = +0,386$) e q01. Em q01, tomando como referência a própria resposta do GeoChat sobre a ortofoto (GT raster) — e não o GeoPackage da Seção 5.4 —, a SR reduz o MAE de estimativa de cobertura de 11,83 para 6,30 pp (pooled), uma melhora de $1,9\times$. O nível estrutural (L2) é o mais fraco: q03 (contagem de campos) satura em zero em ambas as resoluções, inadequada à escala dos tiles. Em todos os níveis, R2 apresenta ganhos iguais ou superiores a R1.

5.4. VQA $\times$ GeoPackage: avaliação cruzada com ground truth vetorial

A Tabela 4 cruza as estimativas de q01 com os percentuais reais do GeoPackage. Globalmente, a SR estima a cobertura do solo com erro 3,6 pp menor que a LR (pooled), e a hierarquia $\text{GT raster} < \text{SR} < \text{LR}$ é consistente nas duas regiões ($17,4 < 19,1 < 22,7$ pp pooled) — a SR recupera a maior parte do sinal semântico relevante para estimativa de cobertura. Os maiores ganhos ocorrem em *bare soil* ($+11,1$ pp) e *agriculture* ($+6,3$ pp) pooled, robustos em ambas as regiões (Figura 1). A Figura 2 ilustra tiles representativos

Tabela 3. VQA estratificada — ganho $\Delta(\text{SR} - \text{LR})$ em TF-IDF e similaridade semântica, por nível e região. n = pares de resposta.

Nível	Região	n	TF-IDF Δ	Sem. Δ
L1 Semântico	R1	1150	+0,223	+0,052
	R2	756	+0,236	+0,056
	pooled	1906	+0,228	+0,054
L2 Estrutural	R1	1150	+0,115	+0,039
	R2	756	+0,156	+0,052
	pooled	1906	+0,131	+0,044
L3 Detalhe fino	R1	1725	+0,099	+0,040
	R2	1134	+0,156	+0,081
	pooled	2859	+0,122	+0,056

das duas regiões, evidenciando a recuperação de detalhes pela SR em diferentes tipos de paisagem.

Tabela 4. MAE (pp) de estimativa de cobertura vs. GeoPackage por classe, região e combinado. $\Delta = \text{LR} - \text{SR}$ (positivo = SR melhor). Menor MAE é melhor. O MAE global usa os tiles cuja resposta de q01 tem formato parseável.

Classe	Região 1 ($n=575$)			Região 2 ($n=378$)			Pooled ($n=953$)		
	LR	SR	Δ	LR	SR	Δ	LR	SR	Δ
forest	37,1	36,6	+0,5	28,8	23,9	+4,9	33,8	31,6	+2,2
agriculture	30,4	26,1	+4,3	50,1	41,0	+9,2	38,3	31,9	+6,3
urban	5,1	3,7	+1,4	5,0	5,8	-0,9	5,1	4,5	+0,5
water	11,5	9,6	+1,9	4,7	13,4	-8,7	8,8	11,1	-2,3
bare soil	29,4	20,2	+9,2	24,4	10,3	+14,0	27,4	16,4	+11,1
Global	22,7	19,2	+3,5	22,6	18,9	+3,7	22,7	19,1	+3,6
GT raster		17,7			16,9			17,4	

6. Conclusão

Este trabalho avaliou, por métricas de PLN e modelos visão-linguagem, se imagens Sentinel-2 super-resolvidas por fusão temporal recuperam conteúdo semântico mensurável. O pipeline proposto vai além de métricas por pixel: o CLIPScore RemoteCLIP imagem-imagem favorece a SR em 952/953 tiles ($\Delta = +0,508$), e as métricas NLP (BLIP e GeoChat) melhoram de forma consistente. A contribuição central — a avaliação cruzada VQA $\times$ GeoPackage — fornece a evidência mais direta e interpretável: a SR reduz o erro global de estimativa de cobertura do solo de 22,7 para 19,1 pp ($-3,6$ pp) frente ao ground truth vetorial e, frente à referência de alta resolução em q01, suas estimativas são $1,9\times$ mais precisas ($11,8 \rightarrow 6,3$ pp) — sem depender de sobreposição léxica ou de pares de alta resolução alinhados. Os maiores ganhos em *bare soil* (+11,1 pp) e *agriculture* (+6,3 pp) revelam que a fusão temporal recupera informação semântica real sobre tipos de cobertura diretamente relevantes para monitoramento agrícola e ambiental.




Figura 1. Ganho da SR (Δ MAE = LR–SR, em pp) na estimativa de cobertura por classe e região. Positivo = SR melhor. Os maiores ganhos ocorrem em *bare soil* e *agriculture*, robustos nas duas regiões.

A validação em **duas regiões geograficamente distintas** (953 tiles combinados) confirma a robustez dos resultados. Observou-se ainda que o ganho semântico global pode coexistir com degradações específicas a certas classes — por exemplo, na Região 2 (água rara) a SR tende a superestimar a classe *water* —, uma nuance útil para calibrar expectativas por tipo de paisagem.

Como trabalhos futuros: (i) ampliar para mais regiões, datas e condições de nuvem, quantificando estatisticamente a variabilidade entre paisagens; (ii) correlacionar as métricas semânticas com tarefas *downstream* (classificação, detecção); e (iii) reformular as perguntas VQA de nível estrutural, que saturaram.

Declaração de Uso de Inteligência Artificial Generativa

Conforme exigido, declara-se o uso de ferramentas de IA generativa neste trabalho. O modelo **Claude Opus 4.8 (Anthropic)**, via Claude Code (versão 2.1.179), foi utilizado para: (i) auxílio na consolidação e análise estatística dos resultados das duas regiões (geração de scripts em Python/pandas); (ii) geração de código de plotagem (matplotlib) das figuras consolidadas; e (iii) revisão gramatical do texto. Os modelos **BLIP**, **GeoChat**, **CLIP** e **RemoteCLIP** constituem o objeto de estudo experimental, não ferramentas de redação. Todo o conteúdo — código e texto — foi integralmente revisado, validado e é de responsabilidade do autor. A concepção da pesquisa, o desenho experimental multi-região e a interpretação dos achados são de autoria própria.

Referências

- Blau, Y. and Michaeli, T. (2018). The perception-distortion tradeoff. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 6228–6237. <https://arxiv.org/abs/1711.06077>.
- Dong, C., Loy, C. C., and Tang, X. (2016). Accelerating the super-resolution convolutional neural network. In *European Conference on Computer Vision (ECCV)*, pages 391–407. <https://arxiv.org/abs/1608.00367>.

- Hessel, J., Holtzman, A., Forbes, M., et al. (2021). CLIPScore: A reference-free evaluation metric for image captioning. In *Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 7514–7528. <https://aclanthology.org/2021.emnlp-main.595/>.
- Kuckreja, K., Danish, M. S., Naseer, M., et al. (2024). GeoChat: Grounded large vision-language model for remote sensing. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. <https://arxiv.org/abs/2311.15826>.
- Li, J., Li, D., Xiong, C., and Hoi, S. (2022). BLIP: Bootstrapping language-image pre-training for unified vision-language understanding and generation. In *International Conference on Machine Learning (ICML)*, pages 12888–12900. <https://arxiv.org/abs/2201.12086>.
- Lin, C.-Y. (2004). ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out (ACL Workshop)*, pages 74–81. <https://aclanthology.org/W04-1013/>.
- Liu, F., Chen, D., Guan, Z., et al. (2024). RemoteCLIP: A vision language foundation model for remote sensing. *IEEE Transactions on Geoscience and Remote Sensing*, 62:1–16. <https://arxiv.org/abs/2306.11029>.
- Lu, X., Wang, B., Zheng, X., and Li, X. (2018). Exploring models and data for remote sensing image caption generation. *IEEE Transactions on Geoscience and Remote Sensing*, 56(4):2183–2195. <https://doi.org/10.1109/TGRS.2017.2776321>.
- Nguyen, N. L., Anger, J., Davy, A., et al. (2021). Self-supervised multi-image super-resolution for push-frame satellite images. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pages 1121–1131. <https://doi.org/10.1109/CVPRW53098.2021.00123>.
- Papineni, K., Roukos, S., Ward, T., and Zhu, W.-J. (2002). BLEU: a method for automatic evaluation of machine translation. In *Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 311–318. <https://aclanthology.org/P02-1040/>.
- Radford, A., Kim, J. W., Hallacy, C., et al. (2021). Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning (ICML)*, pages 8748–8763. <https://arxiv.org/abs/2103.00020>.
- Reimers, N. and Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 3982–3992. <https://arxiv.org/abs/1908.10084>.
- Wang, Z., Bovik, A. C., Sheikh, H. R., and Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612. <https://doi.org/10.1109/TIP.2003.819861>.

Tiles representativos das duas regiões — LR / SR / GT




Figura 2. Tiles representativos das duas regiões (LR / SR / GT), ilustrando ganhos da SR: recuperação de detalhes de água, correção de solo exposto e melhora na descrição de áreas agrícolas.